

# Wstęp do prognozowania

ASC 2025

---

Piotr Żoch

- Jakość prognozy
- Prognoza naiwna
- Średnia ruchoma
- Wygładzanie wykładnicze

## Jakość prognozy

---


- **Interpolacja:** wyznaczenie wartości funkcji w pewnym przedziale, w którym funkcja ma znane wartości dla pewnych argumentów z tego przedziału
  - Wygładzanie.
- **Ekstrapolacja:** wyznaczanie wartości funkcji na zewnątrz przedziału, w którym wartości tej funkcji są znane.
  - Prognozowanie.

- Niech  $y_t$  oznacza faktyczną wartość zmiennej w okresie  $t$ , a  $y_t^f$  **wartość prognozowaną** ( $f$  jak *forecast*, inne częste oznaczenie to  $\hat{y}_t$  lub  $y_t^*$ ).
- **Błąd prognozy** to

$$e_t := y_t - y_t^f$$

- Uwaga: to błąd **ex post** - musimy znać faktyczną wartość!
- Typowe podejście: dzielimy dane na dwa podzbiory: *training set* i *test set*
  - *training set* wykorzystujemy do estymacji parametrów modelu
  - *test set* wykorzystujemy do oceny jakości prognoz

# Jakość prognozy



Źródło: [http://uc-r.github.io/ts\\_benchmarking](http://uc-r.github.io/ts_benchmarking)

- Błędy prognozy

$$e_t = y_t - y_t^f$$

powinny:

- mieć średnią zero (inaczej prognoza *obciążona*)
- być nieskorelowane (inaczej nie wykorzystaliśmy części informacji w danych)
- Pożądane właściwości:
  - stała wariancja
  - rozkład normalny

- **Błąd prognozy ex ante:** opisuje *dopuszczalność* prognozy.
  - przed upływem czasu, na który prognoza była ustalona
- **Błąd prognozy ex post:** opisuje *trafność* prognozy.
  - można obliczyć, gdy znana jest realizacja zmiennej prognozowanej
  - to nimi będziemy się zajmować głównie na tych zajęciach



## Miary błędów ex post

- Notacja: używamy  $n$  obserwacji do prognozy na okresy  $n + 1, n + 2, \dots, T$ .
- **MAE** - mean absolute error

$$\frac{1}{T - n} \sum_{t=n+1}^T |e_t|$$

- **MSE** - mean square error

$$\frac{1}{T - n} \sum_{t=n+1}^T e_t^2$$

- **RMSE** - *root* mean square error

$$\sqrt{\frac{1}{T - n} \sum_{t=n+1}^T e_t^2}$$

- Powyższe *nie* spełniają warunku unormowania (niejasna interpretacja).

- **MAPE** - mean absolute *percentage* error

$$\frac{1}{T-n} \sum_{t=n+1}^T \left| \frac{e_t}{y_t} \right| \times 100\%$$

- **AMAPE** - *adjusted* MAPE

$$\frac{1}{T-n} \sum_{t=n+1}^T \left| \frac{e_t}{y_t + y_t^f} \right| \times 100\%$$

- Często interesuje nas przedział, w którym  $y_t$  będzie znajdować się z określonym prawdopodobieństwem.
- Na przykład, jeśli założymy że błędy prognozy mają rozkład normalny, to

$$y_{t+h} \in \left[ y_{t+h}^f - 1.96\hat{\sigma}_h, y_{t+h}^f + 1.96\hat{\sigma}_h \right]$$

z prawdopodobieństwem 0.95, gdzie  $\hat{\sigma}_h$  to oszacowanie odch. standardowego błędu prognozy o horyzoncie  $h$ .

- $\hat{\sigma}_1$  można obliczyć szacując odchylenie standardowe reszt.
- $\hat{\sigma}_h$  zazwyczaj rośnie wraz z  $h$ . Obliczenie nieco trudniejsze, zwłaszcza gdy reszty są ze sobą skorelowane.

# Metody naiwne

---

- Najprostszy typ metod wykorzystywanych do prognozowania.
- Założenie: brak zmian czynników oddziałujących na zmienną prognozowaną.
  - stosowane w przypadku niewielkich wahań przypadkowych zmiennej zależnej.
- Zazwyczaj niska jakość prognoz.

- Najprostsza prognoza naiwna:

$$y_t^f = y_{t-1}$$

gdzie  $y_t^f$  to prognoza wartości zmiennej zależnej na moment  $t$  a  $y_{t-1}$  to faktyczna wartość tej zmiennej w momencie  $t - 1$ .

- Możemy też mieć prognozę z horyzontem  $h$ :

$$y_{t+h}^f = y_t$$

- Co z trendem, sezonowością?

## Metody średniej ruchomej

---



- Wykorzystywane do
  - **wygładzania** szeregu czasowego ( $X_{11}/X_{12}/X_{13}$ )
  - **prognozowania** - prognozowana wartość zmiennej to średnia z  $k$  poprzednich obserwacji

$$y_t^s = \frac{1}{2n+1} \sum_{i=-n}^n y_{t-i}$$

gdzie  $y_t^s$  to wartość zmiennej w okresie  $t$  po wygładzaniu (*smoothed*) a  $y_{t-n}, y_{t-n+1}, \dots, y_{t+n}$  to faktyczne wartości zmiennej.

- Do wygładzania używamy obserwacji w okresie  $t$  oraz  $n$  poprzedzających i  $n$  kolejnych obserwacji.
- Częste oznaczenie:  $k = 2n + 1$  ( $k$  to stała wygładzania szeregu).

$$y_t^f = \frac{1}{k} \sum_{i=t-k}^{t-1} y_i$$

gdzie  $y_t^f$  to prognozowana wartość zmiennej w okresie  $t$  a  $y_{t-k}, y_{t-k+1}, \dots, y_{t-1}$  to faktyczne wartości zmiennej.

- Do prognozowania używamy obserwacji w okresie  $t - 1$  oraz  $k - 1$  poprzedzających obserwacji.
- Dla  $k = 1$  sprowadza się do metody naiwnej.

## Jak wybrać $k$ ?

- Jakie  $k$  jest najlepsze?
- Pomysł: jak dobrze prognozujemy dane, które zaobserwowaliśmy?
  - błąd prognozy *ex post*.
- Szukamy  $k$ , które minimalizuje

$$MSE_k := \frac{1}{T-k} \sum_{t=k+1}^T (y_t - y_t^f)^2$$

- Obserwacje starsze mają mniejsze znaczenie

$$y_t^f = \sum_{i=t-k}^{t-1} w_{i+t+k+1} y_i$$

gdzie

$$\sum_{i=1}^k w_i = 1$$

$$0 < w_1 < w_2 < \dots < w_k \leq 1$$

# Metody wygładzania wykładniczego

---

- Stosowane w przypadku braku trendu i sezonowości

$$y_t^f = \alpha y_{t-1} + (1 - \alpha) y_{t-1}^f$$

alternatywnie

$$y_t^f = y_{t-1}^f + \alpha (y_{t-1} - y_{t-1}^f)$$

- Skąd nazwa?

$$\begin{aligned}y_t^f &= \alpha y_{t-1} + (1 - \alpha) y_{t-1}^f \\&= \alpha y_{t-1} + (1 - \alpha) [\alpha y_{t-2} + (1 - \alpha) y_{t-2}^f] \\&= \alpha y_{t-1} + \alpha (1 - \alpha) y_{t-2} + (1 - \alpha)^2 y_{t-2}^f \\&= \alpha y_{t-1} + \alpha (1 - \alpha) y_{t-2} + \alpha (1 - \alpha)^2 y_{t-3} + \dots\end{aligned}$$

- Coraz mniejsze wagi przeszłych obserwacji.



- Jak wybrać  $\alpha$ ?
- Najczęściej  $\alpha \in [0.2, 0.3]$ . Niższa wartość = dłuższa pamięć.
  - Dla  $\alpha = 0$  mamy  $y_t^f = y_{t-1}^f$
  - Dla  $\alpha = 1$  mamy  $y_t^f = y_{t-1}$
- Za  $y_1^f$  podstawia się  $y_1$  lub średnią z kilku pierwszych obserwacji.
- W przypadku występowania trendu stosowane **podwójne** wygładzanie wykładnicze.

- Poziom + trend.

$$y_{t-1+k}^f = L_{t-1} + kT_{t-1}$$

gdzie poziom to

$$L_t = \alpha y_t + (1 - \alpha) (L_{t-1} + T_{t-1})$$

a trend to

$$T_t = \beta (L_t - L_{t-1}) + (1 - \beta) T_{t-1}$$

- Równanie prognozy na okres  $t > T$ :

$$y_t^f = L_T + (t - T) T_T$$

gdzie:

- $y_t^f$  - prognoza zmiennej wyznaczona na moment  $t$
- $L_T$  - wygładzona wartość zmiennej prognozowanej na okres  $T$
- $T_T$  - wygładzona wartość przyrostu trendu na okres  $T$
- $T$  - liczba obserwacji zmiennej prognozowanej

- W przypadku metody Holta mamy:

$$L_t = y_t^f + \alpha (y_t - y_t^f)$$

$$T_t = T_{t-1} + \alpha\beta (y_t - y_t^f)$$

$$y_t^f = L_{t-1} + T_{t-1}$$

- Poziom + trend + sezonowość.

$$y_{t-1+k}^f = L_{t-1} + kT_{t-1} + S_{t+k-m(z+1)}$$

$$L_t = \alpha (y_t - S_{t-m}) + (1 - \alpha) (L_{t-1} + T_{t-1})$$

$$T_t = \beta (L_t - L_{t-1}) + (1 - \beta) T_{t-1}$$

$$S_t = \gamma (y_t - L_{t-1} - T_{t-1}) + (1 - \gamma) S_{t-m}$$

gdzie  $m$  oznacza długość cyklu sezonowego (np. 4 albo 12) a  $z = \lfloor \frac{(k-1)}{m} \rfloor$ .

- Poziom + trend  $\times$  sezonowość.

$$y_{t-1+k}^f = (L_{t-1} + kT_{t-1}) \times S_{t+k-m(z+1)}$$

$$L_t = \alpha \left( \frac{y_t}{S_{t-m}} \right) + (1 - \alpha) (L_{t-1} + T_{t-1})$$

$$T_t = \beta (L_t - L_{t-1}) + (1 - \beta) T_{t-1}$$

$$S_t = \gamma \left( \frac{y_t}{L_{t-1} + T_{t-1}} \right) + (1 - \gamma) S_{t-m}$$

gdzie  $m$  oznacza długość cyklu sezonowego (np. 4 albo 12) a  $z = \lfloor \frac{(k-1)}{m} \rfloor$ .